

Development of a CNN-based Skin Disease Classification Model

TEAM 예쁜나이 23살 김나연. 이도영. 오연재

01 Introduction

현대인들은 여드름과 같은 경미한 피부 트러블부터 염증성·전염성 피부질환에 이르기까지 다양한 피부 문제를 겪고 있다. 이러한 피부질환은 계절과 환경에 상관없이 발생하며, 조기 발견이 어려울 경우 치료 지연과 심리적 스트레스, 일상생활의 불편을 초래한다. 특히 비전문가가 스스로 질환의 종류를 정확히 구분하기 쉽지 않아 초기 대응이 늦어지는 경우가 많다. 이러한 문제를 해결하기 위해 피부질환을 빠르고 정확하게 분류할 수 있는 기술의 필요성이 점점 커지고 있다.

2 Objectives


본 연구의 목적은 합성곱 신경망(CNN) 기반 딥러닝 모델을 구축하여 주요 피부질환을 자동으로 분류할 수 있는 시스템을 개발하는 것이다. 전문가의 상담을 받기 전, 비전문가도 자신의 피부 상태를 신속하게 확인할 수 있도록 함으로써 초기 진단 보조, 적절한 임시 대응, 의료 접근성 향상에 기여하고자 한다. 이를 통해 유사한 형태의 피부질환을 시각적으로 구별하기 어려운 문제를 기술적으로 보완하고, 보다 효율적인 피부 건강 관리에 도움을 주는 것을 목표로 한다.

4 Modeling

● 모델링 과정

3단계(Tri-stage) 전이학습(Transfer Learning) 모델 학습 파이프라인을 구현

1. Stage 1 — Frozen Base Training (기능 추출 학습, 50 epochs)
사전학습된 모델의 기본(Backbone)층을 모두 열리고, 새로 추가한 분류기(Classifier)만 학습.
2. Stage 2 — Partial Fine-tuning (부분 미세조정, 50 epochs)
백본 모델의 상위 1/3 레이어를 언프리즈(unfreeze) 하여 조금 더 깊은 수준의 모델 튜닝을 진행.
3. Stage 3 — Full Fine-tuning (전체 미세조정, 50 epochs)
백본의 모든 레이어를 언프리즈 하고 매우 작은 learning rate로 전체 모델을 정교하게 조정.



● 모델 학습 진행 상황

1. 빠른 학습: 초기 에포크부터 정확도가 빠르게 상승.
2. 수렴 (Convergence): 약 60 에포크 부근에서 훈련 및 검증 정확도 모두 80% 목표치를 훨씬 넘어서 안정적으로 수렴.
3. 성능: 120 에포크 현재, 훈련 정확도(96.06%)와 검증 정확도(93.26%) 모두 매우 높은 수준에 도달.

Conclusion

본 연구에서는 여드름(Acne), 습진(Eczema), 기생충감염/벌레물림(Infestations/Bites), 흑색종(Melanoma) 등 4가지 주요 피부질환을 대상으로 합성곱 신경망(CNN) 기반 분류 모델을 구축하고, 약 94%의 전체 정확도와 높은 AUC 값을 통해 우수한 분류 성능임을 확인하였다. 특히 흑색종과 같이 임상적으로 치명적인 질환에 대해 오진 없이 안정적인 예측을 수행하였다는 점에서, 제안한 모델이 피부질환의 조기 발견과 진단 보조 도구로 활용될 수 있는 가능성을 보여준다.

또한, 모델의 성능을 통해 이미지 기반 피부질환 분류 문제에서 전이학습과 단계적 미세조정 전략이 효과적으로 작동함을 확인하였으며, 이는 제한된 규모의 데이터 환경에서도 실질적인 분류 성능을 확보할 수 있는 하나의 방법론적 대안을 제시한다.

결국, 본 연구는 현재 단계에서는 제한된 데이터와 질환 범위를 다루는 소규모 연구이지만, 향후 더 다양한 임상 데이터를 포함한 대규모·고품질 데이터셋으로 확장될 경우, 실제 의료현장에서 활용 가능한 실질적 피부질환 분류 인공지능 시스템으로 발전할 수 있는 중요한 출발점이라는 점에서 의의를 가진다.

3 EDA

- 데이터셋의 루트 디렉토리를 정의
- 이미지를 224×224로 resize
- 원-핫 레이블(4차원 벡터)로 변경
- train/val 8:2 비율로 분할
- 데이터 증강(flip, rotation, zoom, contrast, brightness, gaussian noise) 이후 모델 일반화 능력을 향상시키기 위해 훈련 데이터에 적용



Original image



Augmentation image


● 예측결과 및 성능 평가

Best Validation Accuracy: 94.04%

Final Validation Accuracy: 93.01%

- | | |
|--|--|
| 1. Acne
F1: 0.94
Precision/recall 밸런스 좋음 | 2. Eczema
F1: 0.94
recall이 높아서 놓치는 사례가 거의 없음 |
| 3. Infestations_Bites
F1: 0.80 가장 낮음
Precision:0.90
틀린 예측보다 놓치는 수가 더 많음
recall :0.72
정답인데 놓치는 경우 많음 | 4. Melanoma
F1: 1.00
클래스 특징이 명확해서
안정적 예측 가능 |

Class	Precision	Recall	F1-score
Acne	0.9469	0.9386	0.9427
Eczema	0.9141	0.9613	0.9371
Infestations/Bites	0.8966	0.7222	0.8000
Melanoma	1.0000	1.0000	1.0000



Confusion Matrix				
True Label	Acne	Eczema	Infestations_Bites	Melanoma
	107	6	1	0
	4	149	2	0
	2	0	26	0
Predicted Label	0	0	0	81

모델은 다음 수의 샘플을 정확하게 분류:

- Acne: 107개
- Eczema: 149개
- Infestations_Bites: 26개
- melanoma: 81개

-Acne, melanoma: AUC=1.00:

두 클래스를 다른 클래스와 완벽하게 구별할 수 있음.

-Infestations_Bites: AUC가 0.95로 가장 낮음.


-평균 AUC 값:

1) micro-average ROC curve (area = 0.99) (분홍색 점선):

모든 클래스의 예측을 하나로 모아 계산한 평균 AUC로, 전체 모델의 예측 성능

2) macro-average ROC curve (area = 0.98) (진한 파란색 점선):

각 클래스의 AUC를 단순 평균하여 계산한 값.



6 Conclusions and Discussions

Discussions

현재 제안한 모델은 제한된 범위의 피부질환과 제한된 규모의 이미지 데이터를 중심으로 학습되었기 때문에, 다양한 연령·피부 톤·촬영 환경을 충분히 반영하지 못했다는 한계를 가진다. 이러한 한계를 보완하기 위해, 향후 연구에서는 고려대학교 안암병원 및 고려대학교 메디컬센터에서 수집되는 실제 임상 피부 이미지 데이터를 추가로 확보 연계하여, 보다 다양한 환자군과 촬영 조건을 아우르는 확장된 데이터셋을 구축하고자 한다. 이를 통해 외부 검증을 수행함으로써, 의료기관·장비·환경이 달라져도 일관된 성능을 유지할 수 있는 범용적인 모델로 고도화할 수 있을 것으로 기대된다.

아울러 데이터의 양과 질을 지속적으로 향상시키고, 대상 질환의 범위를 건선, 주사, 기타 양성·악성 종양 등으로 확대함으로써, 현재의 4분류 모델을 보다 포괄적인 다중 피부질환 진단 플랫폼으로 발전시키고자 한다. 장기적으로는 본 연구에서 제시한 모델과 학습 전략을 기반으로, 일반 사용자가 스마트폰으로 손쉽게 자신의 피부 상태를 확인할 수 있는 모바일 자가 진단 서비스, 원격진료 시스템, 1차 의료기관 및 전문병원에서 활용 가능한 임상용 보조 진단 소프트웨어(Clinical Decision Support System, CDSS) 등으로의 상용화 가능성을 모색함으로써, 실제 의료현장과 일상생활에서 활용 가능한 진단 도구로 발전시키고자 한다.

Data Used kaggle) Skin Diseases + Cancer Comprehensive Dataset

Dataset Size 1 acne 여드름(593) 2 Eczema 습진(1010) 3 Infestations/Bites 기생충감염/벌레물림(524) 4 melanoma 흑색종(438)